

Прогнозирование временных рядов — Favorita Grocery Sales

1. Описание проекта

Цель проекта — прогнозирование ежедневных продаж для пар на основе исторических данных и внешних факторов.

Задача - прогнозирование будущих значений продаж на горизонте 16 дней. Для прогнозирования используются исторические признаки временных рядов, календарные признаки, а также экзогенные. Были рассмотрены простые baseline модели, модель машинного обучения и модель глубинного обучения.

2. Данные

Основной датасет содержит:

- date — дата
- store_nbr — идентификатор магазина
- item_nbr — идентификатор товара
- unit_sales — целевая переменная
- onpromotion — наличие акции


Экзогенные признаки:

- items — характеристики товаров (категория, класс, переиздаваемость)
- stores — информация о магазинах (город, тип, кластер)
- transactions — количество транзакций
- oil — цена нефти (внешний фактор)

В рамках проекта был проведен предварительный анализ данных, из которого были сделаны следующие выводы:

1. Частотность наблюдений дневная. В таблице данные указаны по дням, а на графиках
2. Ряды не являются полностью выровненными. Некоторые ряды начинаются позже, другие имеют пустые участки. Часть товаров вообще появляется только в середине периода. Так как пропусков в данных не выявлено, можно предположить, что товары появляются в продаже в разные дни, некоторые товары могут временно отсутствовать или отсутствуют продажи.
3. Большинство рядов не стационарны. На некоторых можно выделить незначительный тренд среднего уровня продаж. В большинстве из примеров есть заметные изменения дисперсии, резкие скачки.
4. Ряды не похожи, но в целом имеют общую закономерность. Из похожих признаков у некоторых рядов можно выделить много нулевых или очень маленьких значений, у части рядов продажи относительно стабильные, а у других с резкими пиками.

Сезонность была подтверждена графиком автокорреляции с выраженными пиками на лагах 7, 14, 21 и 28.



3. Валидация

Так как в задачах прогнозирования временных рядов нельзя использовать случайное разбиение данных, для прогнозирования использовался time-based валидация. Задача требует прогнозирования на горизонте 16 дней, поэтому в качестве валидационной выборки были использованы последние 16 дней тренировочной.

Основные преимущества такой валидации:

- Данные не перемешиваются
- Минимальный риск data leak
- Имитация реального прогноза

Для ML моделей используется рекурсивный прогноз.

При всех моделях была использована выборка в 5000 самых активных рядов, чтобы с наименьшими затратами ресурсов оценить способности каждой из них. Далее финальная модель обучалась на данных за 1 последний год.

Изначально были попытки обработать 2 года, не хватало RAM для обучения финальной модели. Вероятно, это сильно повлияет на результат, но к сожалению, ресурсов для обучения на всем датасете нет.

4. Модели

Baseline

В качестве бейзлайна были проведены эксперименты с моделями Naive, SeasonalNaive, AutoETS и AutoTheta. Для оптимизации обучения бейзлайнов был использован StatsForecast.

ML

В качестве ML модели был выбран LightGBM.

Изначально бустинг выбран, так как он устойчив к шуму, хорошо работает с нелинейными зависимостями и умеет выявлять сложные зависимости.

LightGBM же выбран из-за скорости обучения. Датасет объемный и обучать CatBoost или XGBoost было бы значительно дольше.

DL (TFT)

Из DL моделей был использован TFT. Она была разработана как раз под такие задачи, хорошо работает с табличными данными, экзогенными признаками и большим количеством рядов. Она способна предсказывать весь горизонт сразу и успешно работает с разными типами признаков. Она так же способна сама вычислять лаги и скользящие средние.

5. Результаты

	Модель	NWRMSLE
1	TFT	0.60185
2	LightGBM	0.603440
3	AutoTheta	1.094865
4	AutoETS	1.113895
5	Naive	1.119741
6	SeasonalNaive	1.136523

AutoTheta оказалась лучшей из четырех бейзлайна. SeasonalNaive и Naive, как и ожидалось, показали себя хуже всех. LightGBM и TFT дали сопоставимый результат, так как оба улавливают сложные зависимости, сезонность и незначительные тренды. Для финального предсказания был выбран LightGBM, так как его обучение занимает гораздо меньше времени при сопоставимых результатах. Возможно, будь у TFT больше эпох, меньше батчи или больше данных, он показал бы лучший результат, но в данный момент ресурсы ограничены и выбор был сделан в пользу более легкой модели, которая показала лучший результат в имеющихся условиях.

Результат также был оценен на выборке за год, NWRMSLE получился 0.5567, а на графике ниже можно увидеть сравнение фактических и предсказанных значений



7. Вывод

На изначальной выборке в 5000 рядов модели LightGBM и TFT показали практически одинаковый результат, обогнав классические статистические модели и наивные прогнозы почти в два раза.

В процессе обучения я столкнулась с несколькими трудностями, в частности проблемы с RAM и сопутствующая необходимость прогружать некоторые ячейки несколько раз.

Так же было предпринято несколько безуспешных попыток приблизить результат валидации к результатам на Kaggle. Результат на Kaggle больше близок к метрикам, которые я получила на бейзлайне. Я проверяла несколько раз, чтобы точно нигде не было утечки данных и перезапускала обучение снова и снова после исправления небольших деталей, но улучшение было не таким, какое хотелось бы.

Возможно, проблема в том, что мои модели обучались на урезанном датасете и не уловили какие-то паттерны, для которых нужно больше данных. Несколько несколько попыток из множества можно увидеть ниже.

 submission.csv Complete (after deadline) · 1d ago	1.02782	1.01118
 submission.csv Complete (after deadline) · 1d ago	1.11012	1.07837
 submission.csv Complete (after deadline) · 1d ago	1.20141	1.19497